Modelos matemáticos y estadísticos aplicados en Big data

Breve descripción:

Equipos móviles (teléfonos, tabletas, relojes, televisores, neveras inteligentes), dispositivos sencillos, hoy son emisores de información, con Internet como medio, proponiendo canales de emisión, receptores, otros equipos o sitios de almacenaje de datos, esperando ser utilizados de la mejor manera y con la rapidez posible; esa es la vida de hoy, a eso le llaman el Internet de las cosas (IoT).

Febrero 2026

Tabla de contenido

Introducción 3

1. Analítica de datos 7

1.1. Modelos matemáticos 7

1.2. Estadística descriptiva 10

1.3. Estadística inferencial 15

2. Técnicas de tomas de decisiones 19

3. Big data 25

4. Paquetes ofimáticos aplicados al modelado de datos 31

Síntesis 37

Material Complementario 38

Glosario 39

Referencias bibliográficas 41

Introducción

Apreciado aprendiz, bienvenido a este componente formativo donde se estudiarán conceptos como Big data, domótica, bases de datos, los cuales son muy conocidos hoy en día. Se pretende formalizar el lenguaje apropiando estos conceptos, mostrando las aplicaciones y la relativa importancia que tienen, y cómo van de la mano con conceptos tradicionales de la matemática y la estadística, para llegar a analizar con herramientas ofimáticas, grandes cantidades de información que serán valiosas en la toma asertiva de decisiones.

En el siguiente video conocerá, de forma general, la temática que se estudiará a lo largo del componente formativo.

Video 1. Modelos matemáticos y estadísticos aplicados en big data – Introducción

Enlace de reproducción del video

Síntesis del video: Modelos matemáticos y estadísticos aplicados en big data - Introducción
Sabía que la década de los 90 fue una época importante para el desarrollo tecnológico, esto debido a que abrió el paso para la tecnología actual, en estos años comenzaron a llegar avances de manera constante y la figura empresarial se empezó a convertir en un factor clave para los tiempos que se avecinaban. hasta el inicio de la década de los 90 un puesto de trabajo constaba de un computador de los antiguos panzudos de color blanco, un teléfono de línea fija, un equipo de sonido ambiental armado por módulos, un televisor grande y pesado, un reproductor de video tipo vhs. El correo llegaba a la dirección física por medio de empresas de correo o a casilleros privados postales, si se contaba con un beeper el sujeto era considerado una persona sofisticada. Para enviar una carta documento o texto rápidamente, se usaba el asombroso fax que llegaba casi inmediatamente aunque demoraba casi 20 minutos para enviar 15 páginas. En la actualidad con un equipo móvil una laptop un teléfono móvil o una sencilla tableta se obtienen todos los servicios, para cada dispositivo existen aplicaciones que resuelven; música, televisión, correos instantáneos, conexión con las aerolíneas para reserva en tiempo real de tiquetes aéreos, registros de ingreso, traslados de dinero entre cuentas, todo a través de un equipo inteligente que genera datos de todo tipo con todos los involucrados en las diferentes transacciones que se

realizan, datos estructurados como listados de pasajeros con un destino específico o no estructurados como los likes que se realizan en las redes sociales para algún evento específico.

La estadística que antiguamente se operaba solo en libros o cuadernos, hoy se puede percibir en las tendencias de las publicaciones en las redes sociales, que las publicaciones se conviertan en virales o no, la viralidad virtual es un tema estadístico es regresión estadística, depende de la moda de la que más se repite. Esto es la estrategia del marketing online el mundo se encuentra inmerso en datos con variables y parámetros estadísticos de todo tipo.

Un ciudadano es un dato estadístico a quien le corresponde un número de identificación ID un seguro de salud concatenado con este número y es un contacto para muchos en las redes sociales, pero la red social es un prospecto para que en términos de mercadeo alguien con una necesidad a quien se le puede crear o generar un producto a partir de esta necesidad,

¿cómo hacerlo?

Las Cookies son una herramienta estadística aplicada al mercadeo y Útil para empresas que trabajan con los crm customer relationship management gestor de la relación con los clientes o marketing relacional, permiten diligenciar de forma metódica y centralizada las relaciones de una empresa con sus clientes y para buscar en estas tendencias futuros clientes.

En este componente formativo se investigan y se estudian con más profundidad los temas relacionados con este auge tecnológico y con lenguajes como datos, estadística, muestra y otras herramientas asociadas con este tema bienvenido.

1. Analítica de datos

Para empezar este aprendizaje, definamos qué es la analítica de datos. Se refiere a todas las acciones que permiten recolectar, administrar, gestionar y analizar datos, con el objeto de buscar oportunidades de negocio en el mercado, así como también encontrar óptimos productivos desde el análisis de datos suministrados por: empleados, formatos, dispositivos móviles, maquinaria inteligente, entre otros; permite gestionar acciones de mejora de forma rápida y eficaz, e igualmente es muy útil en la toma de decisiones proactivas para anticipar eventos.

El análisis de datos debe ser inteligente depurando, seleccionando, segmentando la información que sea pertinente para el objeto de análisis, así como también al desechar la información que no sea útil. La rapidez en el análisis de información, también es una acción valiosa y recurrente, porque el intercambio de información llega en segundos, que pueden ser críticos para tomar decisiones asertivas y a tiempo.

En la analítica de datos, encontramos temas como modelos matemáticos y estadística descriptiva e inferencial, para llegar a las técnicas de toma de decisiones. A continuación, lo invitamos a estudiar cada uno de estos temas.

1.1. Modelos matemáticos

Comencemos con los modelos matemáticos, los cuales son la representación simbólica en lenguaje o términos matemáticos, de cualquier evento o fenómeno físico, químico, económico, social o tecnológico. A través de ellos se pueden realizar “observaciones de comportamiento” simbólicos, repetitivos, para conocer el grado del comportamiento real o la cercanía con el modelo; igualmente, para medir, inferir, ajustar, valorar o hasta desechar una variable observada. En administración, es

relevante y fundamental la utilidad de los modelos matemáticos, a través de la investigación de operaciones, la programación lineal y los modelos cuantitativos, buscando optimizar o resolver algunos fenómenos que se presentan a menudo en las organizaciones, reduciendo la incertidumbre en la toma de decisiones organizacionales.

Los modelos matemáticos son conceptos simbólicos, de carácter muy amplio o muy cerrado, lo que hace que sean bastante diversos, siendo a veces difíciles de caracterizar, parametrizar y mucho menos estandarizar, pero sí se ha logrado que cumplan con las siguientes características:

- **Que sean equivalentes**: se refiere al grado de "acercamiento" de la realidad, con el modelo. Generalmente, se mide de forma porcentual, debiendo cumplir como mínimo un 75 % con respecto al original, para que el modelo sea válido.
- **Que sean objetivos**: deben encontrarse libres de vicios de: juicio, sensorial, física, social, u otra entidad que distraiga del objetivo de la observación; asimismo, deben someterse a repeticiones, ajustando los parámetros de observación y de comportamiento de la realidad, versus el modelo. Deben validarse con variables no sesgadas.
- **Que sean simples**: el modelo es el objetivo, se busca que sea más sencillo, más comprensible y calculable.
- **Que sean sensibles**: los modelos no siempre son inflexibles; deben ser flexibles a cambios del comportamiento real, y van articulados con la objetividad y con la equivalencia.

- **Que sean estables**: las variaciones que se presenten en la realidad, deben ser igualmente correspondientes en magnitud en el modelo; a grandes variaciones reales, grandes variaciones en el modelo y viceversa.
- **Que sean universales**: se basa en que el modelo debe haber satisfecho procesos de pruebas en diferentes ambientes, que sirvan de referencia general para comportamientos reales, bajo los mismos parámetros.

Hay que mencionar, además, que el modelo matemático es un lenguaje que, bien leído, se interpreta como debe ser; asimismo, tiene que contener una gramática que interprete el fenómeno o evento observado y estudiado, de tal forma, que la traducción de la realidad al modelo, represente de la mejor y veraz forma posible, el fenómeno real, y así permitir que se puedan realizar simulaciones con alto grado de probabilidad de éxito, o sea, que el modelo represente, en algo, la realidad que se quiere expresar en ese lenguaje matemático, para cuantificar en datos, y volver a la realidad y corroborar lo calculado.

Los tipos de modelo se pueden clasificar por:

A. Origen de la información

- **Heurísticos**: se centran en las causas, se estudian los orígenes de los fenómenos de causa natural.
- **Empíricos**: se realizan desde la observación, con experimentos directos. Son experimentales.

B. Tipo de representación

- **Cualitativo**: lo que interesa es el comportamiento del fenómeno, la tendencia de este o la conducta de algunos atributos, sin importar su valor numérico.

- **Cuantitativo**: utiliza la matemática para determinar valores precisos del comportamiento del fenómeno y se pueden realizar operaciones y análisis complejos

C. Aleatoriedad

- **Determinista**: es un valor preciso sin incertidumbre, que parte de valores determinados ya conocidos.
- **Estocástico**: hace uso de la probabilidad, con cierta incertidumbre de éxito o fracaso.

D. Uso

- **Simulación**: utiliza herramientas tanto heurísticas como probabilísticas, para llegar a un resultado; los eventos se pueden medir (cuantitativo), prediciendo situaciones, partiendo de valores reales del presente.
- **Control**: modelos matemáticos que son útiles para verificar el desempeño de un proceso o comportamiento de una o varias variables con parámetros de entrada y salida, así como variables con máximos y/o mínimos (fronteras de control).
- **Optimización**: son modelos matemáticos planteados de acuerdo con una situación de una problemática específica, brindando varias posibilidades de respuesta y seleccionando, generalmente, la más conveniente en términos de costo, tiempo u otra variable representativa (el óptimo).

1.2. Estadística descriptiva

El siguiente aspecto trata de la estadística, rama de la matemática que recoge, organiza, jerarquiza, ordena, clasifica y analiza datos e información. Solo tomaremos el

concepto descriptivo de la estadística, como es el análisis de eventos, analizando datos agrupados y no agrupados. Estos datos pueden ser variables estadísticas, las cuales se dan como un parámetro que asume las características propias de una población, objeto de algún estudio.

Estas variables pueden ser:

- **Variable cuantitativa**: adquiere características que se pueden expresar con valores numéricos; pueden ser de tipo discreto (se expresan números enteros naturales, por ejemplo, el número de personas en un cine, la cantidad de vehículos en un parqueadero) o continuas (se expresan con números decimales, como el peso, la estatura o la velocidad).
- **Variable cualitativa**: toma atributos que describen cualidades y características específicas que describen una población objeto de estudio, sin utilizar parámetros numéricos; pueden ser ordinales (se refieren a un tipo de orden o secuencia, por ejemplo, alto, medio, bajo, generan algún tipo de nivel a seguir) o nominales (se refieren a atributos como el color de un objeto, la intensidad de este, o los sabores que se pueden apreciar en las comidas, no tienen jerarquías).

Cuando hablamos de estadística descriptiva es importante conocer qué son las tablas de frecuencia, los histogramas y los gráficos.

A continuación, estudiaremos cada uno de estos términos:

- **Tabla de frecuencia**: después de recolectar datos, la tabla de frecuencias ordena, jerarquiza y clasifica los datos recolectados (cualitativos o cuantitativos), procurando asignar las cantidades correspondientes por

intervalos o categorías asignadas, para análisis e informes posteriores, de acuerdo con las necesidades requeridas.

- **Histograma**: es un gráfico de barras que representa los datos de la tabla de frecuencia; el ancho de cada barra es el intervalo (marca de clase); para el caso de datos continuos, cada evento es el ancho de barra para datos discretos. El alto de cada barra es la frecuencia (número de veces que se repite el evento).
- **Gráfico**: la mente humana recuerda y procesa más rápido, útil y eficazmente imágenes, gráficos y formas, que las matrices, tablas, o textos largos y aburridos. Los gráficos son veraces, visuales, llenos de colores y dinámicos, lo que genera en nuestra mente mayor grado de recordación, mejorando el proceso epistemológico. Sencillez, claridad y precisión, hacen que los informes sean más fluidos, más fáciles de analizar, y recepcionar mejor una respuesta ante ellos. En un gráfico se puede condensar mucha información, haciendo que resalten las características y atributos de variables que podrían ser más difíciles de estructurar en una tabla o matriz.

Y dentro del rango de los gráficos, encontramos diferentes tipos de ellos

Conozcamos cuáles son estos tipos:

A. **Gráfico dispersión**: es el clásico gráfico de la línea recta, donde se tiene una variable dependiente, que puede tomar cualquier valor, y otra, que depende del valor de la otra. Existe una correlación entre las dos variables: directas (ambas variables van en el mismo sentido, por ejemplo, si X, aumenta, Y aumenta), o inversas (si X aumenta, Y disminuye).

B. **Gráfico de líneas**: es una representación gráfica en un eje cartesiano, de la relación que existe entre dos variables, reflejando con claridad los cambios producidos. Se suele utilizar para presentar tendencias temporales.

C. **Pictograma**: es un gráfico que representa, mediante figuras o símbolos, las frecuencias de una variable cualitativa o discreta. Al igual que los gráficos de barras suelen usarse para comparar magnitudes o ver la evolución, en el tiempo, de una categoría concreta.

D. **Gráfico de barras**: es la representación, tipo cartesiano, donde el eje X representa las categorías o atributos de la variable (cualitativa o cuantitativa); en el eje Y, se representan las frecuencias (cantidad que presentan estas categorías según los intervalos en que se encuentren), y pueden ser verticales u horizontales, simples o dobles, en dos o tres ejes o dimensiones.

E. **Gráfico circular**: es una representación curva de las frecuencias relativas de una variable cualitativa o discreta que permite, de una manera sencilla y rápida, su comparación. El círculo representa la totalidad que se quiere observar y cada porción, llamada sector, representa la proporción de cada categoría de la variable con respecto al total.

Desde otro punto de vista, existen distintos tipos de información que, de acuerdo con el uso que se les dé y cómo se representen, generalmente son transversales a las áreas funcionales organizacionales.

Uno de ellos, se refiere a las medidas o parámetros de tendencia central, que son números que se ubican buscando el centro de la distribución (concentración) de los datos de un grupo de observaciones, agrupadas o no agrupadas.

Las medidas más utilizadas y conocidas son:

- **Media aritmética**: conocida como promedio, es el valor que tendrían los datos, si todos ellos fueran iguales o, también, el valor que correspondería a cada uno de los datos de la distribución si su suma total se repartiera por igual.
- **Mediana**: si se ordenan todos los datos, de menor a mayor, es el valor que ocupa la posición central. Si el número de datos es par, la mediana es la media aritmética de los dos centrales.
- **Moda**: la moda es el valor que más se repite o, lo que es lo mismo, el que tiene la mayor frecuencia.

Continuemos con las medidas de variabilidad o dispersión, las cuales se definen como las medidas estadísticas orientadas en dar a conocer qué tan lejanas o próximas se encuentran las puntuaciones de una variable, con respecto a la media o promedio aritmético. Estas medidas, son contrarias a las de tendencia central porque, precisamente, miden la "dispersión" o distancia desde el centro de los datos.

Las más conocidas son:

- **Desviación estándar**: este parámetro mide realmente qué tan lejana se encuentra la distribución de datos, con respecto a un parámetro de medida central; aumenta conforme aumenta la dispersión.
- **Varianza**: se conoce como varianza a la raíz cuadrada que se desprende de una desviación estándar, la cual permite que las industrias de manufactura puedan trabajar con precisión en su producción, y reduzcan su índice de errores.

1.3. Estadística inferencial

Desde otro ángulo, tenemos la estadística inferencial, la cual está encargada de hacer deducciones a partir de muestras, que deben contener todas las características y propiedades de la población.

La estadística inferencial tiene sus propias herramientas y mecanismos para llevar a cabo su objetivo; para esto están los intervalos de confianza, pruebas de hipótesis, desviación estándar, la prueba de chi-cuadrado, entre otras. La regresión se considera otra de las ramas fuertes que, a nivel inferencial, brinda grandes posibilidades a la organización, dando patrones de proyecciones y pronósticos de ventas, producción y análisis de inventarios en almacén. Por ende, la estadística inferencial es sumamente útil en el análisis de poblaciones y tendencias, para hacerse una idea posible de las acciones y reacciones, de cara a condiciones específicas. Esto no significa que se las pueda predecir fielmente, ni que estemos en presencia de una ciencia exacta, pero sí de una aproximación, posible, al resultado final.

Algunos ejemplos de la aplicación de la estadística inferencial son:

- Sondeos de tendencia de voto
- Análisis de mercado
- Epidemiología médica

Es necesario recalcar que la población es el conjunto total de datos y la muestra es una parte que se selecciona de esa población, para obtener la información que se necesita y con la que se va a trabajar.

Es así como la población generalmente se considera, de acuerdo a unos estimados de cálculo:

- **Población estadísticamente finita**: que tiene fin; toda población bajo un estimado convencional inferior a 100.000 se considera finita, aunque puede variar según cómo se aborde el objeto de investigación, siempre y cuando no genere sesgos o errores de estimación estadística.
- **Población estadísticamente infinita**: se trata de aquella población que no tiene fin. Por ejemplo, el número de planetas que existen en el Universo, aunque puede que sea finito; el número es tan grande y desconocido, que estadísticamente se asume como infinito. Pero también para facilidad de cálculos, una población que requiere ser estudiada como es la estimación demográfica poblacional (grupos de personas reunidas en un lugar) de la ciudad de Bogotá (con más de 9 millones de habitantes), se puede considerar como infinita.

Asimismo, si se quiere hacer una buena investigación, la calidad de la muestra estadística es esencial. De nada sirve realizar las métricas estadísticas más complejas con los modelos más sofisticados, si la muestra estadística está sesgada, es decir, si la muestra no es representativa.

Por eso, cuando se quieren obtener datos para una muestra que sea representativa, se deben tener en cuenta aspectos como:

- **Tamaño suficientemente grande**: no existe un tamaño ideal para deducir la muestra; para esto existen fórmulas matemáticas que relacionan la población con el tipo de variable (discreta o continua), la fórmula también estima si la población es finita o infinita.
- **Aleatoriedad**: la selección de los datos de una muestra estadística debe ser aleatoria, es decir, debe ser totalmente al azar. Si en lugar de realizarlo al

azar, se realiza un proceso de selección de datos planificado, se está introduciendo un sesgo a la obtención de datos.

Existen diferentes tipos de muestreo según el tipo de variable, el método, o el tipo de población.

Conozcamos cada uno de ellos:

A. **Tipos de muestreo**

- **Muestreo probabilístico**: existe igual probabilidad de estar o no en la muestra, por parte de todos los elementos o individuos.
- **Muestreo aleatorio simple**: es un conjunto de variables aleatorias independientes e idénticamente distribuidas; todas tienen las mismas posibilidades de ser elegidas.
- **Muestreo por conglomerado**: la población se encuentra ya agrupada previamente y de estos grupos se extraen los individuos para conformar la muestra.
- **Muestreo sistemático**: en este caso, la población se enumera y se agrupa en equipos de 10 personas. Posteriormente, se selecciona a un miembro de cada equipo para elaborar la muestra.
- **Muestreo estratificado**: en este caso, la población se divide en subgrupos o estratos, con base en las variables de estratificación.
- **Muestreo no probabilístico**: no aleatoriedad en la selección; esta depende del método y de la subjetividad del seleccionador.
- **Muestreo de bola de nieve**: en primer lugar, se seleccionan diferentes sujetos. Luego, estos sujetos colaboran para encontrar a más sujetos que tengan relación con ellos.

- **Muestreo por cuotas**: la población es elegida en función a unas características determinadas.
- **Muestreo internacional o por conveniencia**: es una muestra elegida por los propios investigadores, según su interés o cercanía.

2. Técnicas de tomas de decisiones

El siguiente aspecto, se refiere a la toma de decisiones. A cada momento se están tomando decisiones; algunas veces automáticas, sin ningún tipo de consulta o ayuda de herramientas o expertos; otras veces se toman decisiones planeadas, verificando qué pasa si, creando escenarios con altas probabilidades de éxito, o qué pasa si las probabilidades son bajas; otro aspecto es el de manipular variables, creando simulaciones sobre situaciones, buscando puntos críticos y sobre estos puntos tomar decisiones óptimas.

El ser y el quehacer cotidiano demandan gran cantidad de decisiones, desde las más sencillas hasta las más complejas y sofisticadas, todas igual de importantes, porque decidir bien, puede ser un arte o una capacidad esencial.

Según estudios, a diario se toman más de 1.000 decisiones y una cuarta parte se relaciona con los alimentos que ingerimos; estas decisiones no se detectan, porque generalmente se hacen inconscientemente; la decisión no se toma desde criterios mentales analizados, sino desde criterios de supervivencia, emotividad o simplemente por reacciones orgánicas, como la sensación de “hambre”, que casi de inmediato se satisface, sin pensar en el cómo, el porqué, el cuánto o el cuándo.

Siempre existen alternativas de opciones para decidir a nivel organizacional. La organización debe “reaccionar” tomando decisiones en todo momento, en finanzas, en recursos humanos (RRHH), en mercadeo, en producción, Seguridad y Salud en el Trabajo (SST); en fin, todas las áreas corporativas son objeto de toma de decisiones. Ahora bien, la diferencia radica básicamente, en que corporativamente, las tomas de decisiones deben ser planeadas, documentadas, analizadas y, finalmente, accionadas, utilizando herramientas desarrolladas específicamente para lograr bajar el grado de

incertidumbre; es bien importante ejecutar las acciones de mejora que resulten de las evaluaciones y esa es una excelente decisión.

Los tipos de decisión van muy ligados al tipo de empresa, así como a la magnitud de su ejercicio o de la cantidad de empleados. A continuación, se presentan las más comunes y transversales.

- **Decisiones de dirección**: este tipo de decisiones son las que se realizan en las reuniones directivas, asambleas de dirección, juntas de socios, donde, desde la dirección, se planean normas y políticas a seguir a nivel macro. Estas decisiones generalmente afectan a mediano y largo plazo, el direccionamiento general de la organización.
- **Decisiones estratégicas**: las decisiones estratégicas se encargan de preparar el futuro de la empresa, es decir, son las decisiones que se toman para obtener resultados a mediano y largo plazo. Estas decisiones las toma la dirección o la gerencia de la empresa, dentro de escenarios que pueden entrañar diferentes grados de riesgo. Son direcciones estratégicas, por ejemplo, la planificación financiera, las políticas de retribución y salir al mercado internacional.
- **Decisiones Individuales**: básicamente, es la autonomía que tiene todo empleado (administrativo u operativo) de tomar decisiones de acuerdo con su rol y conocimiento; estas decisiones también tienen consecuencias en el engranaje total de la empresa, dependiendo de la responsabilidad y grado que tenga en la organización.
- **Decisiones operativas**: son aquellas que se toman para realizar la gestión diaria de la empresa. Estas decisiones pueden tomarlas los trabajadores de

forma individual, o los departamentos correspondientes. Son ejemplo de decisiones operativas: la adaptación de la normativa de protección de datos, la selección de proveedores y el control de cobros y pagos.

- **Decisiones rutinarias o programadas**: estas decisiones son de rutina, programadas, planeadas, incluso sus variantes pueden ser planteadas con anticipación; se toman de forma individual o grupal y forman parte del flujo de procesos.
- **Decisiones de riesgo**: las decisiones de riesgo son excepcionales, puesto que se toman solo en situaciones críticas o de riesgo para la empresa. Una mala decisión en este tipo de escenario, puede significar consecuencias graves para la empresa.

Lo invitamos a ver el siguiente video, donde conoceremos, a través de un ejemplo, la importancia de la toma de decisiones.

Video 2. Ejemplo de toma de decisiones

Enlace de reproducción del video

Síntesis del video: Ejemplo de toma de decisiones
La lectura sobre el discurso del método ha dejado a Renato con dudas. Renato se desempeña como ingeniero de producción en una empresa que desarrolla partes electrónicas para equipos móviles. Esta lectura lo ha confrontado fuertemente y anda racionalizando todo lo que hace a diario; nada de su quehacer cotidiano lo ha dejado en automático. Esto de tomar decisiones de mi vida diaria no es tan fácil cuando lo razono, piensa Renato. ¿pensar en cepillarme los dientes?, ¿decidir cuánto tiempo me demoro haciéndolo?, ¿pensar cómo el cepillo repasa diente por diente?, se experimenta largo y tedioso. En el aspecto organizacional de la empresa se toman todo tipo de decisiones, y en cualquier momento: ¿cuándo debo parar una máquina para mantenimiento?, ¿en cuánto tiempo lo debo hacer?, ¿quién lo va a hacer?, ¿cómo lo va a hacer? ¿Y cómo afecta a la producción haber detenido este equipo? Ambas experiencias, aunque parezcan muy dispares y con grados de dificultad y responsabilidad diferentes, requieren un alto grado de planeación, coordinación y hasta logística para que el proceso se realice. ¿Qué tal que Renato se vaya a cepillar y se dé cuenta de que no tiene crema dental y que no planeó comprarla en el mercado? Una mala decisión que no se concretó porque no la anotó en la lista del mercado; se le pasó por alto y en el supermercado, por la emoción de ver el six pack de su cerveza preferida en oferta,

decidió ponerla en el carro de compras. Otra decisión que aún no sabe si es mala o buena; y es más, Renato ni lo ha pensado.

¿Qué tal detener la producción porque el ingeniero de mantenimiento quiso examinar la máquina hoy, ya que el fin de semana se va de pesca y no quiere perder su excursión? Una decisión no planeada, la de la máquina, sin coordinar ni articular con los otros procesos.

Ahora Renato está entendiendo a Descartes: “sin pensar no existimos”, no accionamos; tomamos malas decisiones.

Cuando Renato llega a la planta de producción, verifica todas las órdenes pendientes. Llama al encargado del inventario de materia prima y pregunta por dos insumos de importancia para él. Le responden que llegarán con un retraso de ocho días porque hay problemas de importación; Renato verifica que solo tiene materia prima para tres días.

En este caso no le pasará lo que le sucedió con la crema dental. Ha previsto aprovechar el espacio pendiente de cinco días: dos para finalizar la producción del modelo FV2, que no requiere la materia prima en retraso; y el resto para programar mantenimiento preventivo de tres máquinas, que tarda dos días, y le queda un día adicional para aseo general.

Decisiones que se toman en un segundo pueden generar valor o producir pérdidas de tipo económico, o incluso de vidas humanas. Para tomar una decisión fundamental, Renato accionó: pensó, verificó en registros, hizo una llamada, analizó, concluyó y, finalmente, decidió optimizar los recursos existentes.

La lógica y los datos indican que ha tomado una buena decisión.

Ahora, exploremos en el siguiente documento, las diferentes herramientas, modelos o instrumentos que nos pueden servir para la toma de decisiones, el cual se encuentra: **Anexo 1. Herramientas, modelos e instrumentos para la toma de decisiones, ubicado en la carpeta anexos.**

3. Big data

El siguiente aspecto a estudiar, es un término que se encuentra presente en la vida cotidiana de todos; viene en cada dispositivo que tenga alguna conexión a Internet, un teléfono, un televisor, una nevera, una cámara de video, la domótica de la casa, una máquina que regule el caudal de agua de un río, todos ellos, enviando información 24–7 los 365 días al año, sin descanso, generando espacios y cantidades de información que manualmente sería imposible de gestionar. El concepto Big data precisamente, hace referencia a la acumulación de grandes cantidades de datos, así como su análisis por medio de máquinas y equipos de cómputo, con el fin de generar o perfilar patrones de comportamiento de información.

En Big data, probablemente lo más importante antes que la velocidad de flujo de datos y la capacidad de almacenamiento, es conocer el tipo de datos que se pueden hallar, en términos de estructurados, semiestructurados y no estructurados.

Ampliemos la información sobre cada uno de ellos:

A. **Datos estructurados**: son los datos con los que se pueden construir bases de datos, generando campos y registros, los cuales son veraces; se pueden relacionar y articular con otras bases de datos de diferentes fuentes y son datos cuantitativos.

La fecha de nacimiento, el número de la tarjeta de crédito o débito, la información de la cuenta de trading, la dirección de la vivienda, el GPS (Sistema de Posicionamiento Global), son tipos de datos estructurados.

Este tipo de datos se dividen en dos categorías:

- **Datos estructurados generados por una máquina**: en estos datos no existe ningún tipo de manipulación humana; los mensajes y datos son enviados y recibidos por máquinas.
- **Datos estructurados generados por humanos**: aquí debe haber interacción del humano en algún aspecto del proceso con la máquina.

B. **Datos semiestructurados**: se llaman semiestructurados porque en estos datos se presentan unas partes estructuradas y otras no.

Estos datos fluyen sin estar en una base de datos que relacionen proveedores con clientes u otro interesado, pero están soportados en formatos de texto de diferentes fuentes y su estructura u organización obedece a un orden semántico.

El código HTML (Lenguaje de Marcas de Hipertexto), es un ejemplo de datos semiestructurados, debido a que no hay límite en la cantidad de datos, pero los jerarquiza semánticamente.

C. **Datos no estructurados**: el símil más cercano de datos no estructurados, son los datos de tipo cualitativo, los cuales no se pueden analizar con herramientas matemáticas convencionales, porque carecen de un modelo lógico estructurado que permita hacer el análisis cuantitativamente, relacionando datos entre bases de datos de igual, o diferentes orígenes.

No es una tarea fácil encontrar la información escondida dentro de los datos no estructurados. Requiere de análisis avanzado y un alto nivel de experiencia técnica,

para realmente marcar la diferencia. Este puede ser un cambio costoso para muchas empresas.

El dilema actual, es que en los datos no estructurados encontramos la información más valiosa de los clientes o prospectos, información suministrada por hábitos que no se entregarían a un cajero o a una encuesta, información privilegiada que se obtiene de redes sociales con "likes" o que pertenecen a una red social muy particular; fotos o videos subidos en ciertos lugares "exóticos" por ejemplo, comprendiendo más del complejo comportamiento o intención del cliente moderno. Esta importancia nombrada, radica en las acciones de predicción que las organizaciones pueden hacer a los clientes, partiendo del conocimiento profundo de sus hábitos, incluso a clientes desde sus segmentos bien específicos, casi que, individualizando a un cliente en particular, para llegar a las características propias de alguien en especial.

No todas las compañías optarán por la misma metodología con respecto al desarrollo y la creación de sus capacidades con tecnologías Big data. Sin embargo, en todos los sectores existe la posibilidad de recurrir a estas nuevas tecnologías y analíticas para mejorar la toma de decisiones y el rendimiento, tanto a nivel interno como en el mercado.

En definitiva, el Big data es una combinación de siete características, con las cuales las empresas pueden obtener una ventaja posicional frente a sus competidores, contribuyendo hacia el éxito asegurado.

- **Volumen de datos**: el principal factor del concepto Big data, se refiere a la cantidad de datos que se generan en diferentes tipos de emisores o dispositivos y de diferentes tipos de datos (estructurados, no estructurados

o semi estructurados), esperando ser procesados y analizados. Esta cantidad aumenta exponencialmente en todo momento, cada minuto que ingresa una nueva organización al mundo digital.

- **Velocidad de los datos**: los datos se deslizan por grandes autopistas de información en diferentes rutas, buscando llegar rápidamente a sus receptores; entonces se hace importante su monitorización, control y análisis, con el fin de conocer qué información traen y extractar rápidamente la importancia de esta, para tomar acciones, como puede ser, por ejemplo, la información de fraude en alguna organización.
- **Variedad de los datos**: las formas, las fuentes, los tipos, el comportamiento y cómo se registran los datos, hace que sean estructurados; por ende, fáciles de relacionar y seguir, como también sin formato o no estructurados ambos, en todo caso, siendo útiles como elemento de información para los fines y necesidades particulares de la organización.
- **Veracidad de los datos**: conocer la providencia y origen de los datos, así como su validez, hace que cobren importancia y relevancia, basados en el tiempo, para validar este origen.
- **Viabilidad de los datos**: una organización que procura depurar sus procesos y mantener la efectividad, en alto grado, es una organización exitosa, pero parte de esa organización y de ese éxito se inicia con la depuración de la información, la clasificación de los datos, segmentarlos y un uso eficaz de estos, en las tomas de decisiones.

- **Visualización de los datos**: hay un dicho popular que dice: “todo entra por los ojos”; en este caso, la depuración, selección, clasificación, jerarquización y análisis de los datos no lo son todo, su presentación es de suma importancia, los datos se deben presentar de una manera sencilla, clara y concisa, lo más transparentes posible, habiendo encontrado patrones evidentes y ocultos, mostrándolos con todas sus relaciones. Existen aplicaciones y herramientas que hacen que la presentación de los datos sea más completa, estética y elocuente.
- **Valor de los datos**: la axiología es la ciencia que estudia el valor de las cosas; sin querer entrar en detalles filosóficos, en la gestión de los datos podríamos deducir que el dato por sí solo no tiene valor alguno (teoría subjetivista del valor), pero de la buena depuración, transformación y análisis del dato, al brindar parámetros de decisión, se le otorga valor y es entonces que adquiere la riqueza que fundamenta las decisiones exitosas. Igualmente, existen herramientas poderosas, capaces de extraer de los datos (generalmente no estructurados) información valiosa, en términos de estrategia para las organizaciones.

A. Métodos, técnicas y análisis de manejo de datos masivos

Estudiado el contexto de las herramientas y técnicas tradicionales de análisis de datos aprenderemos, entonces, sobre las herramientas que actualmente se utilizan para el análisis de datos masivos (Big data).

- **Aprendizaje automático**: las máquinas aprenden a comprender patrones de comportamiento, desde los más sencillos hasta los más complejos,

utilizando algoritmos igualmente complicados; desde esa perspectiva, adquieren conocimientos que utilizarán en acciones posteriores, mejorando procesos (machine learning), al ir expandiendo su "memoria interna" con conocimientos, y aumentando fundamentalmente su desempeño, autonomía y automaticidad (inteligencia artificial).

- **Redes de neuronas**: como su nombre lo dice, partiendo del aprendizaje automático las máquinas, a través de algoritmos, aprenden a crear redes de conocimiento e información, aprendiendo patrones nuevos cada vez; una interacción similar al funcionamiento de las neuronas humanas, que lo hacen por redes, y son patrones no lineales, siendo así más rápidas y eficaces.
- **Aprendizaje reglas de asociación**: tiene un cierto parecido con la regresión, buscando la correlación de variables; en este caso, los algoritmos buscan relaciones entre las bases de datos, encontrando en estas relaciones puntos fuertes a la hora de tomar decisiones.
- **Análisis de series temporales**: esta técnica es conocida desde la década de los 70´s donde, a partir de un histórico de datos, se proyectan datos a futuro; la diferencia aquí radica en el volumen, la velocidad y las otras "V" que fundamentan las características del Big data, aplicando algoritmos y máquinas capaces de analizar, en términos de segundos o minutos, los datos para "entregar" respuestas que sean útiles en las decisiones organizacionales.

4. Paquetes ofimáticos aplicados al modelado de datos

Los datos son categorías de variables que se representan con símbolos, números o letras; contienen o transmiten información y pueden ser cuantitativos o cualitativos (concepto desde la estadística). Los datos, por sí solos, no generan valor y deben ser estructurados de alguna forma para obtener un significado informativo; es aquí donde la informática cobra relevancia e importancia porque, finalmente, es desde allí que se categorizan y analizan.

Los datos pueden ser:

- Numéricos
- De texto
- Lógicos
- Estadísticos

Tenga en cuenta que los datos son símbolos aislados, sin contexto, sin valor alguno. Cuando se estructuran, jerarquizan, analizan y visualizan en un entorno o contexto específico acorde con su fuente, se vuelven información y es, en ese momento, donde se pueden tomar decisiones.

Es necesario recalcar que, como característica imprescindible de los datos, es el que se encuentren bajo modelos, los cuales estructuran, de alguna manera, los datos no estructurados buscando encontrar el valor que intrínsecamente contengan los datos. Igualmente, los modelos optimizan así mismo, el poder informativo de los datos estructurados, interactúan no solo con datos en la dinámica actual con características de alta velocidad de gestión de grandes cantidades de datos, sino que además

relacionan información dinámica entre bases de datos, e incluso entre diferentes tipos de modelos, una interacción total.

Conforme la tecnología ha evolucionado y se ha incrementado el volumen de datos, las herramientas convencionales de los paquetes ofimáticos se fueron quedando cortas para el análisis “estático” de las antiguas bases de datos que cambiaban lentamente. Hoy en día, estas herramientas son más poderosas, capaces de analizar “dinámicamente” datos en tiempo real, conforme van cambiando con “delay” en segundo y no en semanas o meses como ocurría antes.

Es necesario almacenar la información similar para poder consultarla en el momento preciso; antiguamente, en las organizaciones, las bases de datos eran sus archivos físicos, clasificados con diferentes metodologías para ser consultados; eran habitaciones llenas de “legajadores” de color café guardados sistemáticamente. Después llegó la era digital, y en la habitación se archivaban no solo libros físicos, sino “discos compactos”, grabados con datos en pdf, jpg, u otro formato; ahora el cuarto o estancia se ha convertido en el sitio donde se encuentra una gran computadora (servidor), que está interactuando con otras estaciones de trabajo en el mismo edificio o afuera, enviando la información a un tipo de dispositivo móvil en cualquier parte del mundo, en algún momento. Ese es el concepto de base de datos actual, es una interacción dinámica y rápida.

Según su variabilidad o sea, la preservación de los datos, así como también su recuperación, las bases de datos se clasifican en:

- **Estáticas**: antiguos análisis históricos hechos por las compañías hasta hace 10 años, depositados en archivos digitales (memorias USB, discos duros), solo para consulta o lectura.
- **Dinámicas**: a diferencia de las estáticas, están en constante cambio, entra y sale información en cuestión de segundos.

Y según su contenido (discrimina el tipo de información que se administra) las bases de datos se clasifican en:

- **Bibliográficas**: contienen diverso material de lectura (libros, revistas, etc.), ordenado a partir de información clave como son los datos del autor, editor, año de aparición, área temática o título del libro, entre muchas otras posibilidades.
- **De texto completo**: se manejan con textos históricos o documentales, cuya preservación debe ser a todo nivel y se consideran fuentes primarias.
- **Directorios**: listados enormes de datos personalizados o de direcciones de correo electrónico, números telefónicos, etc.
- **Especializadas**: bases de datos de información hiperespecializada o técnica, pensadas a partir de las necesidades puntuales de un público determinado que consume dicha información.

A. Sistemas de gestión de bases de datos

Continuemos este estudio con el sistema de gestión de bases de datos (DBMS, Data Base Magnament System), el cual es una aplicación (software) que gestiona no solo una base de datos, sino también varias bases de datos. Es una interfaz que le

permite a los usuarios, interactuar con la información que le brindan sus datos, organizados en bases de datos dinámicas y flexibles.

El sistema de gestión de base de datos, a diferencia de las bases de datos, gestiona, controla, aplica principios y reglas a todas esas relaciones que pueden resultar de la interacción de las bases de datos. Ofrece cánones de seguridad, integridad de los datos y procesos rígidos de auditoría, para el buen uso y prácticas nobles en disposición, suministro y recibo de información, procurando que se cumplan las "V" del Big data.

Los sistemas de gestión de bases de datos pueden clasificarse en varios tipos:

- **Sistema centralizado**: en el que todos los datos residen en una única ubicación y los usuarios pueden acceder a dicha ubicación para manipular los datos.
- **Sistema distribuido**: en el que los datos residen en varios nodos.
- **Sistema federado**: capaz de suministrar datos sin duplicación de datos fuente. Esta categoría a su vez, puede dividirse en:
    - **Una base de datos de acoplamiento libre**: requiere acceso a otras bases de datos de componentes.
    - **Una base de datos de acoplamiento estrecho**: utiliza procesos independientes para trabajar en un sistema federado.
    - **Los sistemas de bases de datos de cadena de bloques**: gestionan transacciones financieras y de otros tipos.

Es así como el DBMS organiza los archivos de su base de datos y proporciona a los usuarios finales más acceso y control sobre sus datos. Para lograrlo, un DBMS

permite a los usuarios manipular los datos en los archivos de sus bases de datos, incluyendo acciones como crear, editar y actualizar cuando sea necesario.

Un DBMS proporciona 5 funciones principales:

a) Conceder a múltiples usuarios acceso simultáneo a una única base de datos.
b) Establecer y mantener normas de seguridad y derechos de acceso de los usuarios.
c) Hacer respaldos de los datos de forma habitual y recuperarlos rápidamente en caso que se produzca una brecha.
d) Establecer reglas y normas de bases de datos para proteger la integridad de los datos.
e) Proporcionar definiciones y descripciones de “diccionario” de los datos disponibles.

B. Herramientas tecnológicas

Finalizamos concluyendo que, el Big data se ha convertido hoy en una prioridad para muchas empresas; así mismo, han surgido abundantes ofertas de administradores de aplicaciones de grandes datos, para atender esta demanda actual de obtener o estructurar información privilegiada a partir de datos (en todas sus formas, características y presentaciones).

Conozcamos las herramientas más importantes:

- **Apache Hadoop**: es una de las precursoras, utilizada por Facebook, de código abierto (gratis), predictiva y con alto nivel de seguridad.

- **Elasticsearch**: procesa datos en grandes cantidades, análisis en tiempo real, con ayuda de gráficos y se pueden realizar consultas complejas.
- **Apache Storm**: se puede usar con cualquier lenguaje de programación, proceso en tiempo real, grandes cantidades de datos.
- **MongoDB**: es no relacional para datos no estructurados o semiestructurados, excelente para teléfonos móviles.
- **Apache Spark**: es gratis, se puede conectar con varias computadoras simultáneamente, aplica machine learning, muy eficaz y rápida.

Recuerde explorar los demás recursos que se encuentran disponibles en este componente formativo; para ello, diríjase al menú principal, donde encontrará la síntesis, el material complementario, entre otros. Además, lo invitamos a resolver la actividad didáctica para reforzar los conceptos estudiados en el componente formativo.

Síntesis

El siguiente mapa conceptual integra los criterios y especificidades de los conocimientos expuestos en el presente componente formativo.

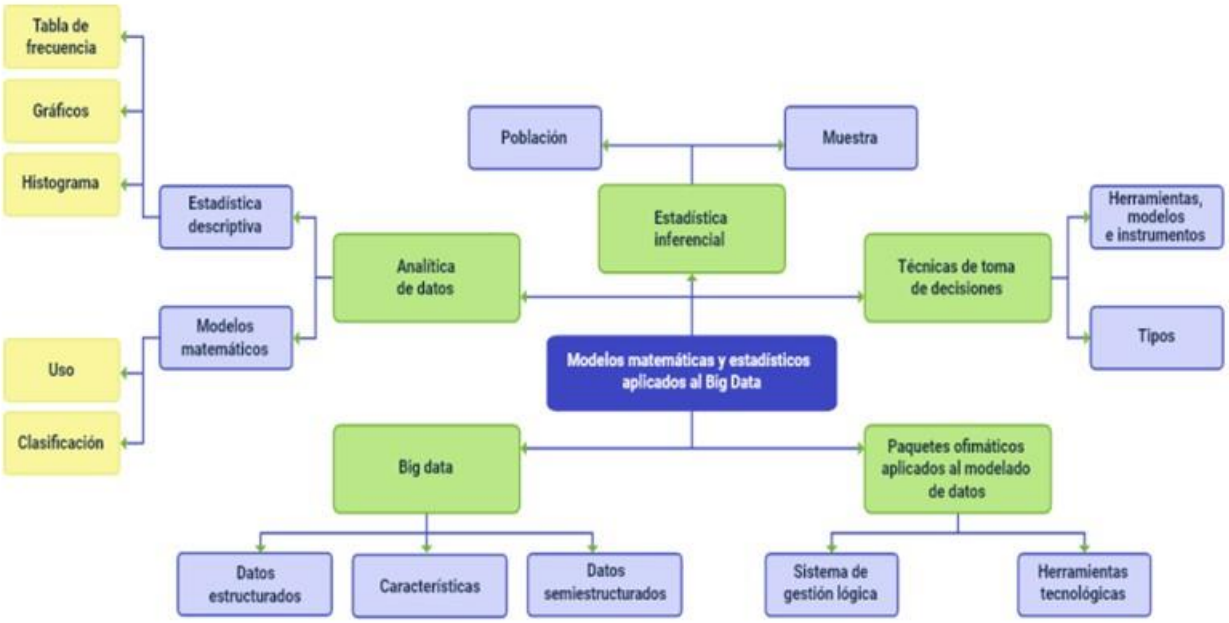

Material Complementario

Tema	Referencia	Tipo de material	Enlace del recurso
Analítica de datos	Virtual Training Lteam. (2016). Análisis de Datos (video). YouTube.	Video	https://www.youtube.com/watch?v=sv6yaVunVms&feature=youtu.be
Big data	EDteam. (2019). ¿Qué es el Big Data? (video). YouTube.	Video	https://www.youtube.com/watch?v=M26iIqmqWkl
Paquetes ofimáticos aplicados al modelado de datos	Concepto.de. (s.f.). Base de datos.	Página web	https://concepto.de/base-de-datos/#ixzz7d75P9SNx
Paquetes ofimáticos aplicados al modelado de datos	Powerdata.es. (2017). 10 técnicas de análisis de datos para estadísticas de big data.	Página web	https://blog.powerdata.es/el-valor-de-la-gestion-de-datos/10-tecnicas-de-analisis-de-datos-para-estadisticas-de-big-data

Glosario

Analítica de datos: permite gestionar acciones de mejora de forma rápida y eficaz, e igualmente es muy útil en la toma de decisiones proactivas para anticipar eventos.

Big data: hace referencia a la acumulación de grandes cantidades de datos, así como su análisis por medio de máquinas y equipos de cómputo, con el fin de generar o perfilar patrones de comportamiento de información.

Cualitativo: toma atributos que describen cualidades y características específicas que describen una población objeto de estudio, sin utilizar para esto algún parámetro numérico.

Cuantitativo: se puede expresar con valores numéricos, pueden ser de tipo discreto o continuo.

Decisión: es la determinación para actuar ante una situación que presenta varias alternativas. La palabra proviene del latín decisio, qué significa opción tomada entre otras posibilidades.

Desviación estándar: es un índice numérico que mide la dispersión con respecto al parámetro que agrupa la distribución de los datos, midiendo el grado de alejamiento (el dato disperso n menos la medida de tendencia central como la media) con respecto a esta, de cada dato individualmente; luego se suman todas estas diferencias, dividido por el número de datos; realmente es un promedio de las diferencias de los datos con respecto a la media. (Nota: se toma la distribución de datos como la población objeto de estudio denominado n).

Estadística: rama de la matemática que recoge, organiza, jerarquiza, ordena, clasifica y analiza datos e información.

Inferencia: hace deducciones a partir de muestras (que deben tener todas las características y propiedades de la población), de allí mide tendencias, infiere propiedades y hasta define conclusiones.

Modelo matemático: es la representación simbólica en lenguaje o términos matemáticos, de cualquier evento o fenómeno físico, químico, económico, social o tecnológico.

Población: se refiere a la cantidad de individuos (personas o grupos de personas), animales (o grupo de estos), cosas o eventos que sean objeto de un estudio o investigación en particular.

Referencias bibliográficas

Castillo, J. A. (2018). Big Data. IFCT128PO. IC Editorial.

Hillier, F. S. y Lieberman, G. J. (2006). Introducción a la investigación de operaciones (8va ed.). Mc Graw Hill.